LAPORAN PRATIKUM DATA ENGINEERING AND BIG DATA SYSTEMS

PERTEMUAN 1

OLEH

Nama : AYUL HUSNAINI

Nim : 105841110423

Kelas : 5 AI-A

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS MUHAMMADIYAH MAKASSAR

2026

1. Import Library

```python
# Import library
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.datasets import load_iris
```

✓ 15.1s Python

- import numpy as np : Digunakan untuk Memanggil library NumPy agar bisa melakukan operasi matematika dan statistik, seperti membuat array angka acak dan menghitung rata-rata.
- import pandas as pd: Digunakan untuk Memanggil library Pandas supaya bisa membuat dan mengolah data dalam bentuk tabel (DataFrame), misalnya untuk data mahasiswa dan nilai.
- import matplotlib.pyplot as plt: Digunakan untuk Memanggil library Matplotlib agar bisa membuat berbagai jenis grafik, seperti grafik garis dan titik dari data nilai.
- from sklearn.datasets import load_iris: Digunakan untuk Memanggil fungsi load_iris dari scikit-learn untuk mengambil dataset Iris yang sering dipakai sebagai contoh data pada Machine Learning.

2. Array Random 20 Angka

```python
import numpy as np

# Mengatur seed agar hasil angka acak tetap konsisten    "Mengatur": Unknown word.
np.random.seed(10)

# Menghasilkan 20 angka acak dengan rentang 0 sampai 100    "Menghasilkan": Unknown word.
data_acak = np.random.uniform(0, 100, 20)    "acak": Unknown word.

print("Daftar Angka Acak:")    "Daftar": Unknown word.
print(data_acak.round(2))    "acak": Unknown word.
print(f"\nRata-rata       : {np.mean(data_acak):.2f}")    "acak": Unknown word.
print(f"Nilai Tengah    : {np.median(data_acak):.2f}")    "Nilai": Unknown word.
print(f"Standar Deviasi : {np.std(data_acak):.2f}")    "Standar": Misspelled word.
```

✓ 0.0s Python

```
Daftar Angka Acak:
[77.13  2.08 63.36 74.88 49.85 22.48 19.81 76.05 16.91  8.83 68.54 95.34
  0.39 51.22 81.26 61.25 72.18 29.19 91.78 71.46]

Rata-rata       : 51.70
Nilai Tengah    : 62.31
Standar Deviasi : 30.01
```

- np.random.seed(10): Digunakan untuk Mengunci hasil angka acak supaya setiap kali dijalankan hasilnya tetap sama (reproducible).

- data_acak = np.random.uniform(0, 100, 20): Digunakan untuk Membuat 20 angka acak dengan rentang antara 0 sampai 100
- print("Daftar Angka Acak:")
  print(data_acak.round(2))
  Digunakan untuk Menampilkan daftar angka acak yang sudah dibulatkan ke 2 angka di belakang koma agar lebih rapi.
- print(f"\nRata-rata : {np.mean(data_acak):.2f}"): Digunakan untuk Menghitung dan menampilkan rata-rata dari angka-angka acak.
- print(f"Nilai Tengah : {np.median(data_acak):.2f}"): Digunakan untuk Menghitung dan menampilkan nilai tengah (median) dari angka-angka acak.
- print(f"Standar Deviasi : {np.std(data_acak):.2f}"): Digunakan untuk Menghitung dan menampilkan standar deviasi, yaitu seberapa jauh angka-angka itu tersebar dari rata-ratanya.

Program tersebut menampilkan 20 angka acak dalam bentuk desimal yang sudah dibulatkan dengan rapi, misalnya seperti 77.13, 2.08, 63.36, dan seterusnya. Setelah daftar angka itu, ditampilkan juga hasil perhitungannya. Nilai rata-ratanya adalah 51.70, nilai tengah (median) berada di 62.31, dan standar deviasinya sebesar 30.01.

3. DataFrame Nilai Mahasiswa & 3 Nilai Tertinggi

```
import pandas as pd

# Penyusunan data nama mahasiswa dan nilai    "Penyusunan": Unknown word.
data_mahasiswa = {    "mahasiswa": Unknown word.
    'Nama_Mahasiswa': [    "Mahasiswa": Unknown word.
        'RM', 'Jin', 'Suga', 'J-Hope', 'Jimin',    "Suga": Unknown word.
        'V', 'Jungkook', 'Jennie', 'Lisa', 'Rose'    "Jungkook": Unknown word.
    ],
    'Nilai': [88, 91, 85, 90, 87, 93, 95, 89, 92, 86]    "Nilai": Unknown word.
}

df_mahasiswa = pd.DataFrame(data_mahasiswa)    "mahasiswa": Unknown word.

# Mengambil tiga baris dengan nilai tertinggi    "Mengambil": Unknown word.
peringkat    "mahasiswa": Unknown word. cSpell    "peringkat": Unknown word.
                View Problem (Alt+F8)    Quick Fix... (Ctrl+.)
print("Ta                                    Misspelled word.
print(df_mahasiswa)    "mahasiswa": Unknown word.
print("\nTiga Mahasiswa dengan Nilai Tertinggi:")    "Tiga": Unknown word.
print(peringkat_atas)    "peringkat": Unknown word.
✓ 0.0s
```

```
Tabel Data Nilai Lengkap:
  Nama_Mahasiswa  Nilai
0             RM     88
1            Jin     91
2           Suga     85
3         J-Hope     90
4          Jimin     87
5              V     93
6       Jungkook     95
7         Jennie     89
8           Lisa     92
9           Rose     86

Tiga Mahasiswa dengan Nilai Tertinggi:
  Nama_Mahasiswa  Nilai
6       Jungkook     95
5              V     93
8           Lisa     92
```

- import pandas as pd: Memanggil library Pandas agar bisa membuat dan mengolah data dalam bentuk tabel (DataFrame).
- df_mahasiswa = pd.DataFrame(data_mahasiswa): Digunakan untuk: Mengubah dictionary data_mahasiswa menjadi tabel DataFrame agar bisa diolah dan ditampilkan.
- peringkat_atas = df_mahasiswa.nlargest(3, 'Nilai'): Digunakan untuk: Mengambil 3 mahasiswa dengan nilai tertinggi dari tabel.
- print("Tabel Data Nilai Lengkap:") print(df_mahasiswa) : Digunakan untukMenampilkan seluruh data mahasiswa dan nilai ujian.
- print("\nTiga Mahasiswa dengan Nilai Tertinggi:") print(peringkat_atas) : Digunakan untuk Menampilkan 3 mahasiswa dengan nilai paling tinggi.

Saat program dijalankan, pertama muncul tabel lengkap yang menampilkan nomor urut di sebelah kiri, lalu sepuluh nama mahasiswa beserta nilai ujian masing-masing. Setelah itu, di bawahnya muncul tabel kedua yang lebih kecil. Tabel ini hanya berisi tiga mahasiswa dengan nilai tertinggi, yaitu Jungkook dengan nilai 95, V dengan nilai 93, dan Lisa dengan nilai 98.

4. Dua Grafik dari Data Nilai

```python
import matplotlib.pyplot as plt

# Membuat pengaturan tata letak grafik berdampingan    "Membuat": Unknown word.
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(14, 6))    "figsize": Unknown word.

# Grafik 1: Line Chart untuk melihat fluktuasi nilai    "Grafik": Unknown word.
ax1.plot(df_mahasiswa['Nama_Mahasiswa'], df_mahasiswa['Nilai'], marker='o', color='teal', linewidth=2)    "maha
ax1.set_title('Fluktuasi Nilai Ujian ')    "Fluktuasi": Unknown word.
ax1.set_ylabel('Skor')    "ylabel": Unknown word.
ax1.tick_params(axis='x', rotation=45)

# Grafik 2: Scatter Plot untuk melihat titik sebaran skor    "Grafik": Unknown word.
ax2.scatter(df_mahasiswa['Nama_Mahasiswa'], df_mahasiswa['Nilai'], color='crimson', s=150, edgecolor='black')
ax2.set_title('Titik Sebaran Skor')    "Titik": Unknown word.
ax2.set_ylabel('Skor')    "ylabel": Unknown word.
ax2.tick_params(axis='x', rotation=45)

plt.tight_layout()
plt.show()
```

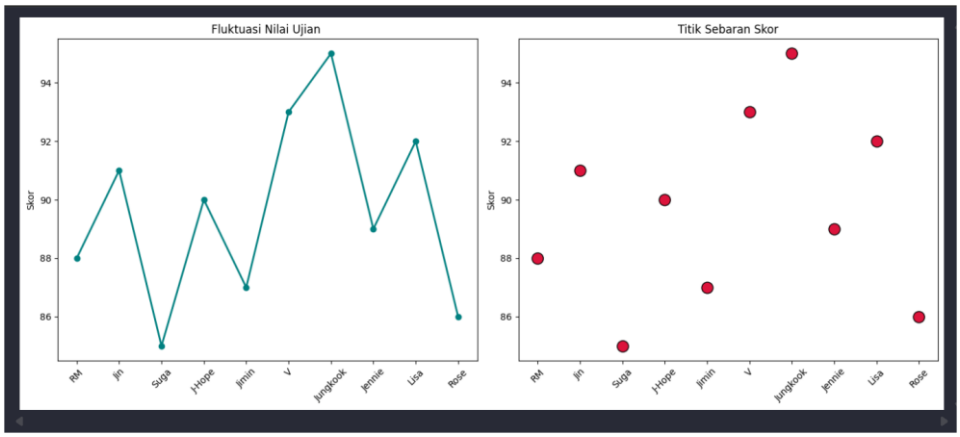

- import matplotlib.pyplot as plt: Digunakan untuk: Memanggil library Matplotlib agar bisa membuat berbagai jenis grafik.
- fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(14, 6)): Digunakan untuk Membuat dua area grafik berdampingan dalam satu kanvas berukuran 14x6 inci.
- ax1.plot(df_mahasiswa['Nama_Mahasiswa'], df_mahasiswa['Nilai'], marker='o', color='teal', linewidth=2): Digunakan untuk Membuat grafik garis untuk melihat naik-turunnya nilai mahasiswa.
- ax1.set_title('Fluktuasi Nilai Ujian ')
  ax1.set_ylabel('Skor')
  x1.tick_params(axis='x', rotation=45)
  Digunakan untuk:
  Memberi judul, label sumbu Y, dan memiringkan nama mahasiswa di sumbu X agar mudah dibaca.

- ax2.scatter(df_mahasiswa['Nama_Mahasiswa'], df_mahasiswa['Nilai'], color='crimson', s=150, edgecolor='black')
  Digunakan untuk Membuat grafik titik (scatter) untuk melihat sebaran nilai mahasiswa.
- ax2.set_title('Titik Sebaran Skor')
  ax2.set_ylabel('Skor')
  ax2.tick_params(axis='x', rotation=45)
  Digunakan untuk Memberi judul, label sumbu Y, dan memiringkan nama mahasiswa di sumbu X pada grafik kedua.
- plt.tight_layout()
  plt.show()
  Digunakan untuk Merapikan tata letak grafik dan menampilkan kedua grafik tersebut.

Saat grafik ditampilkan, terlihat dua grafik yang posisinya berdampingan. Grafik di sebelah kiri berbentuk garis yang menunjukkan naik turunnya nilai ujian tiap mahasiswa, jadi kita bisa langsung melihat polanya. Sedangkan grafik di sebelah kanan berbentuk titik-titik yang memperlihatkan posisi nilai masing-masing mahasiswa secara terpisah berdasarkan besar kecilnya skor.

Di bagian bawah kedua grafik, nama-nama mahasiswa ditulis dengan posisi miring sekitar 45 derajat supaya tulisannya tidak saling bertabrakan dan tetap mudah dibaca.

5. Load Dataset Diabetes & 3 Insight

```python
from sklearn.datasets import load_diabetes

# Memuat dataset diabetes dalam bentuk DataFrame    "Memuat": Unknown word.
dataset_diabetes = load_diabetes(as_frame=True)
df_diabetes = dataset_diabetes.frame

print("Ukuran data:", df_diabetes.shape)    "Ukuran": Unknown word.
print("Kolom:", list(df_diabetes.columns))    "Kolom": Unknown word.

print("\nInsight 1: Dataset Diabetes memiliki", df_diabetes.shape[0], "sampel dan", df_diabetes.shape[1] - 1, "fitur.")
# Karena ini regresi, target tidak berupa kelas melainkan nilai kontinu    "Karena": Unknown word.
print("Insight 2: Target (progres penyakit) berkisar antara",    "progres": Misspelled word.
      round(df_diabetes["target"].min(), 2), "hingga", round(df_diabetes["target"].max(), 2),    "hingga": Unknown word.
      "dengan rata-rata", round(df_diabetes["target"].mean(), 2))    "dengan": Unknown word.
print("Insight 3: Rata-rata BMI =", round(df_diabetes["bmi"].mean(), 2))
```

0.0s Python

```
Ukuran data: (442, 11)
Kolom: ['age', 'sex', 'bmi', 'bp', 's1', 's2', 's3', 's4', 's5', 's6', 'target']

Insight 1: Dataset Diabetes memiliki 442 sampel dan 10 fitur.
Insight 2: Target (progres penyakit) berkisar antara 25.0 hingga 346.0 dengan rata-rata 152.13
Insight 3: Rata-rata BMI = -0.0
```

- from sklearn.datasets import load_diabetes: Digunakan untuk: Memanggil fungsi dari scikit-learn untuk mengambil dataset diabetes.
- dataset_diabetes = load_diabetes(as_frame=True): Digunakan untuk Mengambil dataset diabetes dan langsung mengubahnya ke format DataFrame agar mudah diolah.
- df_diabetes = dataset_diabetes.frame: Digunakan untuk Menyimpan data diabetes ke variabel DataFrame.
- print("Ukuran data:", df_diabetes.shape): Digunakan untuk: Menampilkan jumlah baris dan kolom pada dataset.
- print("Kolom:", list(df_diabetes.columns)): Digunakan untuk: Menampilkan nama-nama kolom (fitur) pada dataset.
- print("\nInsight 1: Dataset Diabetes memiliki", df_diabetes.shape[0], "sampel dan", df_diabetes.shape[1] - 1, "fitur."): Digunakan untukMemberi insight tentang jumlah data dan fitur yang tersedia.
- print("Insight 2: Target (progres penyakit) berkisar antara", round(df_diabetes["target"].min(),2),"hingga", round(df_diabetes["target"].max(), 2), "dengan rata-rata", round(df_diabetes["target"].mean(), 2))

Digunakan untuk Memberi insight tentang rentang dan rata-rata nilai target (progres penyakit).

- print("Insight 3: Rata-rata BMI =", round(df_diabetes["bmi"].mean(), 2)): Digunakan untuk: Memberi insight tentang rata-rata BMI pada data.

Dalam output muncul teks "Ukuran data:" diikuti tuple (442, 11) yang artinya ada 442 baris dan 11 kolom. Di bawahnya tampil "Kolom:" yang merinci nama-nama kolom, dimulai dari 'age', 'sex', 'bmi', 'bp', lalu fitur s1–s6, dan terakhir 'target'. Setelah jeda, baris "Insight 1" menjelaskan bahwa dataset Diabetes ini punya 442 sampel dan 10 fitur (kolom terakhir adalah target). Baris "Insight 2" menunjukkan target (progres penyakit) bernilai antara 25.0 sampai 346.0 dengan rata-rata sekitar 152.13 — jadi targetnya adalah angka kontinu, bukan kelas. Pada baris terakhir, "Insight 3" menampilkan contoh fitur: rata-rata bmi sekitar -0.0 (dataset ini ter-standardisasi), jadi nilainya tidak dalam skala BMI sebenarnya.

6. Kesimpulan

Praktikum ini memberikan pemahaman dasar tentang cara kerja alat-alat pengolahan data di Python. NumPy sangat bisa diandalkan untuk mempercepat proses perhitungan angka. Pandas sangat membantu dalam menata data mentah menjadi bentuk tabel yang enak dibaca dan mudah disaring. Matplotlib menyempurnakan proses tersebut dengan kemampuannya mengubah angka menjadi grafik visual yang jelas. Semua alat dasar ini, ditambah dengan tersedianya dataset bawaan dari scikit-learn, menjadi pondasi awal yang kuat sebelum beranjak ke tahapan proses pemodelan Machine Learning yang lebih rumit.