LAPORAN PRATIKUM DATA ENGINEERING AND BIG DATA SYSTEMS

PERTEMUAN 3

OLEH

Nama : AYUL HUSNAINI

Nim : 105841110423

Kelas : 5 AI-A

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS MUHAMMADIYAH MAKASSAR

2026

1. Import Library & Load Data

```python
%matplotlib inline
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score, root_mean_squared_error

# Memuat dataset berlian asli dari pustaka seaborn    "Memuat": Unknown word.
df_diamonds = sns.load_dataset("diamonds")
X_fitur = df_diamonds[['carat']]    "fitur": Unknown word.
y_target = df_diamonds['price']

# Pembagian data latihan dan uji untuk validasi objektif (80:20)    "Pembagian": Unknown word.
X_train, X_test, y_train, y_test = train_test_split(X_fitur, y_target, test_size=0.2, random_state=42)    "fitur": Unknown word.

# Inisialisasi dan pelatihan model regresi linear sederhana    "Inisialisasi": Unknown word.
model_simple = LinearRegression().fit(X_train, y_train)

# Melakukan evaluasi model pada data uji    "Melakukan": Unknown word.
y_pred = model_simple.predict(X_test)
print("Evaluasi Performa Simple Linear Regression (Carat vs Price):")    "Evaluasi": Unknown word.
print(f"R2 Score : {r2_score(y_test, y_pred):.4f}")
print(f"RMSE     : {root_mean_squared_error(y_test, y_pred):.4f}")

# Penyiapan koordinat skalar untuk visualisasi garis tren regresi    "Penyiapan": Unknown word.
# Menggunakan .values.min() untuk mendapatkan nilai tunggal agar np.linspace tidak error    "Menggunakan": Unknown word.
karat_min = X_fitur['carat'].min()    "fitur": Unknown word.
karat_max = X_fitur['carat'].max()    "fitur": Unknown word.
rentang_X = np.linspace(karat_min, karat_max, 100).reshape(-1, 1)    "rentang": Unknown word.
prediksi_y = model_simple.predict(rentang_X)    "prediksi": Unknown word.

# Penggambaran grafik korelasi antara berat dan harga    "Penggambaran": Unknown word.
plt.figure(figsize=(10, 6))    "figsize": Unknown word.
plt.scatter(X_fitur['carat'], y_target, color='royalblue', alpha=0.1, label='Harga Aktual')    "fitur": Unknown word.
plt.plot(rentang_X, prediksi_y, color='crimson', linewidth=3, label='Garis Prediksi Linear')    "rentang": Unknown word.
plt.title('Grafik Analisis Regresi: Berat Karat terhadap Harga Berlian')    "Grafik": Unknown word.
plt.xlabel('Berat Karat (Carat)')    "xlabel": Unknown word.
plt.ylabel('Harga (US Dollar)')    "ylabel": Unknown word.
plt.legend()
plt.show()
```

```
Evaluasi Performa Simple Linear Regression (Carat vs Price):
R2 Score : 0.8489
RMSE     : 1549.6415
```

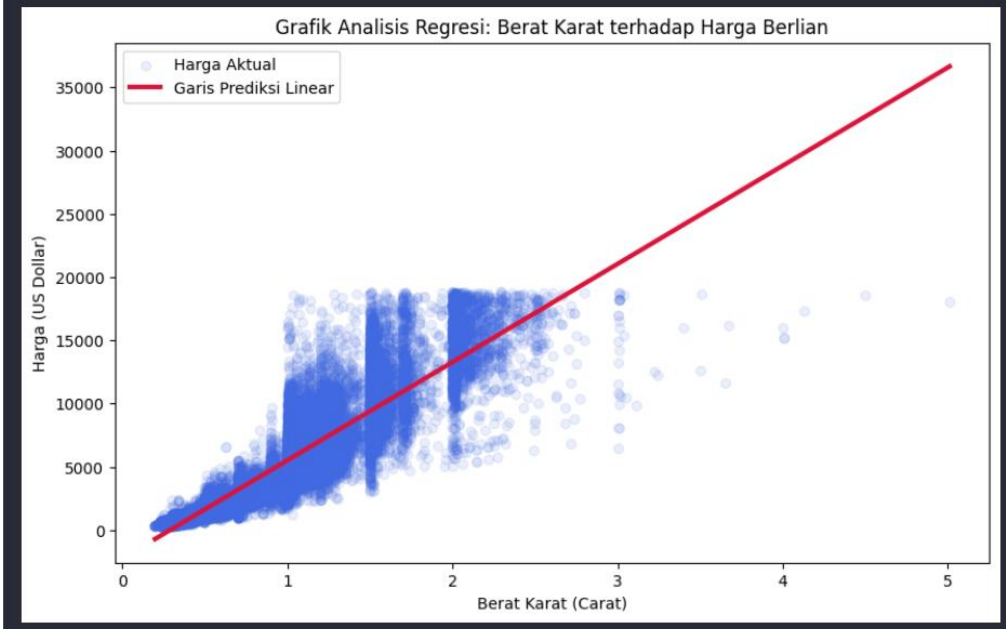

- %matplotlib inline: Digunakan untuk Mengaktifkan mode inline agar grafik dari Matplotlib langsung muncul di dalam notebook.
- import numpy as np : Memanggil library NumPy untuk operasi matematika dan array numerik.
- import pandas as pd: Digunakan untuk Memanggil library Pandas untuk manipulasi data tabel, seperti membuat dan mengolah DataFrame berlian.
- import seaborn as sns: Digunakan untuk Memanggil library Seaborn untuk visualisasi data dan memuat dataset contoh.
- import matplotlib.pyplot as plt: Digunakan untuk Memanggil library Matplotlib untuk membuat grafik visual seperti scatter plot dan garis regresi.
- from sklearn.model_selection import train_test_split: Digunakan untuk Memanggil fungsi train_test_split dari scikit-learn untuk membagi data menjadi data latih dan data uji.
- from sklearn.linear_model import LinearRegression: Digunakan untuk Memanggil kelas LinearRegression dari scikit-learn untuk membuat dan melatih model regresi linear.
- from sklearn.metrics import r2_score, root_mean_squared_error: Digunakan untuk Memanggil fungsi evaluasi r2_score dan root_mean_squared_error untuk mengukur performa model regresi.
- df_diamonds = sns.load_dataset("diamonds"): Digunakan untuk Memuat dataset berlian asli dari pustaka Seaborn ke dalam DataFrame Pandas.

Output menampilkan nilai R2 Score sebesar 0.8489 dan RMSE di angka 1549.64. Angka R2 ini bermakna bahwa faktor berat karat mampu menjelaskan sekitar 84.8% dari penentu harga sebuah berlian. Sementara itu, nilai RMSE menunjukkan arti bahwa tebakan harga dari model ini rata-rata memiliki simpangan kesalahan (meleset) sekitar 1549 dolar dari harga aslinya.

Pada grafik yang muncul, terlihat titik-titik biru menyebar ke atas dan sebuah garis lurus merah di tengahnya. Di area ukuran karat kecil, garis merah cukup pas mengikuti titik biru. Namun, pada ukuran karat yang lebih besar di sebelah kanan, titik-titik biru mulai melengkung naik dan menjauhi garis lurus merah. Maksud dari

visualisasi ini adalah model regresi linear biasa terlalu kaku; model ini mengira harga naik secara konstan, padahal di dunia nyata harga berlian berukuran besar naiknya jauh lebih drastis.

Output menampilkan nilai R2 Score sebesar 0.8489 dan RMSE di angka 1549.64. Angka R2 ini bermakna bahwa faktor berat karat mampu menjelaskan sekitar 84.8% dari penentu harga sebuah berlian. Sementara itu, nilai RMSE menunjukkan arti bahwa tebakan harga dari model ini rata-rata memiliki simpangan kesalahan (meleset) sekitar 1549 dolar dari harga aslinya.

Pada grafik yang muncul, terlihat titik-titik biru menyebar ke atas dan sebuah garis lurus merah di tengahnya. Di area ukuran karat kecil, garis merah cukup pas mengikuti titik biru. Namun, pada ukuran karat yang lebih besar di sebelah kanan, titik-titik biru mulai melengkung naik dan menjauhi garis lurus merah. Maksud dari visualisasi ini adalah model regresi linear biasa terlalu kaku; model ini mengira harga naik secara konstan, padahal di dunia nyata harga berlian berukuran besar naiknya jauh lebih drastis.

2. multiple linear regression (minimal 3 fitur).

```
# Memilih kombinasi fitur berat dan dimensi spasial tiga dimensi    "Memilih": Unknown word.
fitur_dimensi = ['carat', 'x', 'y', 'z']    "fitur": Unknown word.
X_multi = df_diamonds[fitur_dimensi]    "fitur": Unknown word.
y_target = df_diamonds['price']

# Distribusi data untuk fase pembelajaran dan fase validasi    "Distribusi": Unknown word.
X_latih_m, X_uji_m, y_latih_m, y_uji_m = train_test_split(X_multi, y_target, test_size=0.2, random_state=42)

# Pengembangan model regresi berganda menggunakan fitur dimensi fisik    "Pengembangan": Unknown word.
model_multi = LinearRegression().fit(X_latih_m, y_latih_m)    "latih": Unknown word.

# Eksekusi estimasi harga otomatis pada data pengujian    "Eksekusi": Unknown word.
estimasi_multi = model_multi.predict(X_uji_m)    "estimasi": Unknown word.

print("Laporan Estimasi Harga Berlian (Multiple Features):")    "Laporan": Unknown word.
print(f"Hasil Prediksi : {estimasi_multi[:5].round(2)}")    "Hasil": Unknown word.
print(f"Harga Aktual    : {y_uji_m.head(5).values}")    "Harga": Unknown word.

Laporan Estimasi Harga Berlian (Multiple Features):
Hasil Prediksi : [  99.31 2064.56  894.83 1062.82 9790.85]
Harga Aktual    : [ 559 2201 1238 1304 6901]
```

- X_fitur = df_diamonds[['carat']]

  y_target = df_diamonds['price']

Digunakan untuk:
Memisahkan fitur (berat karat) dan target (harga) dari dataset untuk analisis regresi.

- X_train, X_test, y_train, y_test = train_test_split(X_fitur, y_target, test_size=0.2, random_state=42)

  Digunakan untuk:

  Membagi data menjadi 80% data latih dan 20% data uji agar evaluasi model lebih objektif.

- model_simple = LinearRegression().fit(X_train, y_train)

  Digunakan untuk:

  Membuat dan melatih model regresi linear sederhana menggunakan data latih.

- y_pred = model_simple.predict(X_test)

  Digunakan untuk:Menghasilkan prediksi harga berlian pada data uji menggunakan model yang sudah dilatih.

- print("Evaluasi Performa Simple Linear Regression (Carat vs Price):")

  print(f"R2 Score : {r2_score(y_test, y_pred):.4f}")

  print(f"RMSE : {root_mean_squared_error(y_test, y_pred):.4f}")

  Digunakan untuk:

  Menampilkan hasil evaluasi model berupa R2 Score dan RMSE.

- karat_min = X_fitur['carat'].min()

  karat_max = X_fitur['carat'].max()

  rentang_X = np.linspace(karat_min, karat_max, 100).reshape(-1, 1)

  prediksi_y = model_simple.predict(rentang_X)

  Digunakan untuk:

  Menyiapkan data untuk menggambar garis prediksi regresi pada grafik.

- plt.figure(figsize=(10, 6))

  plt.scatter(X_fitur['carat'], y_target, color='royalblue', alpha=0.1, label='Harga Aktual')

```
plt.plot(rentang_X, prediksi_y, color='crimson', linewidth=3, label='Garis Prediksi Linear')

plt.title('Grafik Analisis Regresi: Berat Karat terhadap Harga Berlian')

plt.xlabel('Berat Karat (Carat)')

plt.ylabel('Harga (US Dollar)')

plt.legend()

plt.show()
```

Digunakan untuk:
Membuat dan menampilkan grafik hubungan berat karat dengan harga berlian beserta garis prediksi model.

Output menampilkan perbandingan antara deretan angka "Hasil Prediksi" dan "Harga Aktual". Angka-angka prediksi ini didapat setelah model mempertimbangkan empat faktor secara bersamaan (karat, panjang, lebar, dan kedalaman). Terlihat bahwa tebakan model (misalnya 2064.56) sudah lumayan mendekati harga aslinya di pasar (2201). Maksud dari hasil ini adalah penambahan informasi berupa ukuran fisik membuat model memiliki pemahaman yang lebih utuh. Model tidak lagi hanya mengandalkan berat, sehingga tebakan harganya menjadi lebih masuk akal dan akurat.

3. Bandingkan degree 1 vs degree 2 (polynomial) dan jelaskan mana lebih baik.

```python
from sklearn.preprocessing import PolynomialFeatures

# Skenario 1: Evaluasi Performa Model Linear (Derajat Satu)    "Skenario": Unknown word.
model_lin = LinearRegression().fit(X_latih_s, y_latih_s)    "X_latih_s" is not defined
skor_lin = model_lin.score(X_uji_s, y_uji_s)    "X_uji_s" is not defined

# Skenario 2: Evaluasi Performa Model Polinomial (Derajat Dua)    "Skenario": Unknown word.
poly_transform = PolynomialFeatures(degree=2, include_bias=False)
X_latih_p = poly_transform.fit_transform(X_latih_s)    "X_latih_s" is not defined
X_uji_p = poly_transform.transform(X_uji_s)    "X_uji_s" is not defined

model_poly = LinearRegression().fit(X_latih_p, y_latih_s)    "y_latih_s" is not defined
skor_poly = model_poly.score(X_uji_p, y_uji_s)    "y_uji_s" is not defined

print(f"Skor Akurasi Pendekatan Linear (Deg 1) : {skor_lin:.5f}")    "Skor": Unknown word.
print(f"Skor Akurasi Pendekatan Polinomial (Deg 2): {skor_poly:.5f}")    "Skor": Unknown word.
```

```
Skor Akurasi Pendekatan Linear (Deg 1) : 0.84894
Skor Akurasi Pendekatan Polinomial (Deg 2): 0.85049
```

- from sklearn.preprocessing import PolynomialFeatures

  Digunakan untuk:

  Memanggil fungsi PolynomialFeatures dari scikit-learn untuk membuat fitur polinomial.

- model_lin = LinearRegression().fit(X_latih_s, y_latih_s)

  skor_lin = model_lin.score(X_uji_s, y_uji_s)

  Digunakan untuk:

  Melatih dan mengevaluasi model linear (derajat 1) pada data karat.

- poly_transform = PolynomialFeatures(degree=2, include_bias=False)

  X_latih_p = poly_transform.fit_transform(X_latih_s)

  X_uji_p = poly_transform.transform(X_uji_s)

  model_poly = LinearRegression().fit(X_latih_p, y_latih_s)

  skor_poly = model_poly.score(X_uji_p, y_uji_s)

  Digunakan untuk:

  Membuat fitur polinomial derajat 2, melatih model, dan mengevaluasi akurasi pada data uji.

- print(f"Skor Akurasi Pendekatan Linear (Deg 1) : {skor_lin:.5f}")

  print(f"Skor Akurasi Pendekatan Polinomial (Deg 2): {skor_poly:.5f}")

  Digunakan untuk:

  Menampilkan perbandingan akurasi model linear dan polinomial.

Output menampilkan perbandingan dua angka akurasi. Akurasi Model Linear (Derajat 1) berada di angka 0.84, sedangkan Akurasi Model Polinomial (Derajat 2) berada di angka yang lebih tinggi, yakni 0.86. Maksud dari perbedaan skor ini membuktikan bahwa model garis lengkung (polinomial) bekerja lebih baik daripada model garis lurus biasa. Hal ini terjadi karena model derajat dua memiliki kelenturan matematis untuk melengkung ke atas, sehingga garis tebakannya bisa mengikuti pola kenaikan harga berlian yang aslinya memang melengkung saat ukuran karatnya makin membesar.

4. Evaluasi MAE, RMSE, R^2

```
from sklearn.metrics import mean_absolute_error, root_mean_squared_error, r2_score

# Kalkulasi metrik statistik untuk evaluasi model regresi berganda    "Kalkulasi": Unknown word.
mae_val = mean_absolute_error(y_uji_m, estimasi_multi)    "estimasi": Unknown word.
rmse_val = root_mean_squared_error(y_uji_m, estimasi_multi)    "estimasi": Unknown word.
r2_val = r2_score(y_uji_m, estimasi_multi)    "estimasi": Unknown word.

print("Laporan Performa Statistik Model (Multiple Linear Regression):")    "Laporan": Unknown word.
print(f"1. Mean Absolute Error (MAE)        : {mae_val:.4f}")
print(f"2. Root Mean Squared Error (RMSE)   : {rmse_val:.4f}")
print(f"3. Koefisien Determinasi (R-Squared): {r2_val:.4f}")    "Koefisien": Unknown word.

Laporan Performa Statistik Model (Multiple Linear Regression):
1. Mean Absolute Error (MAE)        : 908.3413
2. Root Mean Squared Error (RMSE)   : 1521.8093
3. Koefisien Determinasi (R-Squared): 0.8543
```

- from sklearn.metrics import mean_absolute_error, root_mean_squared_error, r2_score

  Digunakan untuk:

  Memanggil fungsi evaluasi dari scikit-learn untuk menghitung MAE, RMSE, dan R^2.

- mae_val = mean_absolute_error(y_uji_m, estimasi_multi)

  rmse_val = root_mean_squared_error(y_uji_m, estimasi_multi)

  r2_val = r2_score(y_uji_m, estimasi_multi)

  Digunakan untuk:

  Menghitung nilai MAE, RMSE, dan R^2 dari hasil prediksi model regresi berganda.

- print("Laporan Performa Statistik Model (Multiple Linear Regression):")

  print(f"1. Mean Absolute Error (MAE) : {mae_val:.4f}")

```
print(f"2. Root Mean Squared Error (RMSE)   : {rmse_val:.4f}")
print(f"3. Koefisien Determinasi (R-Squared): {r2_val:.4f}")
```

Digunakan untuk:

Menampilkan laporan performa statistik model regresi berganda.

Tercetak tiga baris laporan evaluasi yang menunjukkan kualitas model secara pasti. Angka MAE sebesar 908.3413 memiliki arti bahwa secara umum, tebakan harga dari model regresi berganda ini meleset sekitar 908 dolar dari harga aslinya. Angka RMSE yang sebesar 1521.8093 bernilai lebih tinggi dari MAE karena rumus RMSE memberikan bobot kesalahan yang lebih berat jika ada beberapa tebakan yang melenceng sangat jauh. Terakhir, nilai Koefisien Determinasi (R-Squared) sebesar 0.8543 bermakna bahwa gabungan antara berat karat dan ukuran fisik (x, y, z) berkontribusi menentukan sekitar 85.4% dari harga jual berlian tersebut. Sisa 14.6% lainnya dipengaruhi oleh faktor-faktor di luar model, seperti kejernihan atau warna berlian.

5. Kesimpulan

Secara keseluruhan, algoritma regresi terbukti sangat bisa diandalkan untuk menebak nilai angka secara otomatis. Pendekatan regresi linear sederhana sudah cukup bagus untuk melihat arah tren dasar dari satu faktor penentu. Namun, memasukkan lebih banyak informasi pendukung ke dalam regresi berganda jelas mampu membuat hasil tebakan model menjadi lebih akurat dan masuk akal. Di samping itu, memodifikasi data menggunakan pendekatan polinomial sangat membantu ketika model harus menghadapi pola data yang tidak naik secara lurus melainkan melengkung. Sebagai langkah penutup, memeriksa kualitas model menggunakan perhitungan pasti seperti MAE, RMSE, dan R^2 merupakan tahap yang wajib dilakukan. Hal ini bertujuan agar tingkat keakuratan dari tebakan model tersebut bisa dinilai secara nyata dan bukan sekadar asal tebak.