LAPORAN PRATIKUM DATA ENGINEERING AND BIG DATA SYSTEMS

PERTEMUAN 5

OLEH

Nama : AYUL HUSNAINI

Nim : 105841110423

Kelas : 5 AI-A

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS MUHAMMADIYAH MAKASSAR

2026

1. Import Library & Persiapan Data

```python
from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.svm import SVC
from sklearn.metrics import accuracy_score, classification_report

# persiapan data    "persiapan": Unknown word.
sumber = load_breast_cancer()    "sumber": Unknown word.
X_train, X_test, y_train, y_test = train_test_split(
    sumber.data, sumber.target, test_size=0.2, random_state=42    "sumber": Unknown word.
)

# scaling wajib karena SVM sensitif skala    "wajib": Unknown word.
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

# dua varian kernel
models = {
    "SVM Linear": SVC(kernel="linear", C=1),
    "SVM RBF": SVC(kernel="rbf", C=1, gamma="scale")
}

for name, model in models.items():
    model.fit(X_train, y_train)
    pred = model.predict(X_test)
    print(f"\n{name} accuracy:", round(accuracy_score(y_test, pred), 3))
    print(classification_report(y_test, pred, target_names=sumber.target_names))    "sumber"
```

```
SVM Linear accuracy: 0.956
              precision    recall  f1-score   support

   malignant       0.93      0.95      0.94        43
      benign       0.97      0.96      0.96        71

    accuracy                           0.96       114
   macro avg       0.95      0.96      0.95       114
weighted avg       0.96      0.96      0.96       114


SVM RBF accuracy: 0.982
              precision    recall  f1-score   support

   malignant       1.00      0.95      0.98        43
      benign       0.97      1.00      0.99        71

    accuracy                           0.98       114
   macro avg       0.99      0.98      0.98       114
weighted avg       0.98      0.98      0.98       114
```

- from sklearn.datasets import load_breast_cancer

  Digunakan untuk:

  Memanggil fungsi load_breast_cancer dari scikit-learn untuk mengambil dataset kanker payudara.

- from sklearn.model_selection import train_test_split

Digunakan untuk:

Memanggil fungsi train_test_split dari scikit-learn untuk membagi data menjadi data latih dan data uji.

- from sklearn.preprocessing import StandardScaler

  Digunakan untuk:

  Memanggil kelas StandardScaler dari scikit-learn untuk melakukan scaling pada fitur numerik agar SVM bekerja optimal.

- from sklearn.svm import SVC

  Digunakan untuk:

  Memanggil kelas **SVC** dari scikit-learn untuk membuat dan melatih model Support Vector Machine.

- from sklearn.metrics import accuracy_score, classification_report

  Digunakan untuk:

  Memanggil fungsi evaluasi **accuracy_score** dan **classification_report** untuk mengukur dan menampilkan performa model klasifikasi.

- sumber = load_breast_cancer()

  X_train, X_test, y_train, y_test = train_test_split(sumber.data, sumber.target, test_size=0.2, random_state=42)

  Digunakan untuk:

  Memuat data kanker payudara dan membaginya menjadi data latih (80%) dan data uji (20%).

- scaler = StandardScaler()

  X_train = scaler.fit_transform(X_train)

  X_test = scaler.transform(X_test)

  Digunakan untuk:

  Melakukan scaling pada data latih dan uji agar semua fitur memiliki skala yang sama.

2. Tuning

```python
# tuning sederhana    "sederhana": Unknown word.
params = []
C_vals = [0.1, 1, 10, 100]
gamma_vals = [0.001, 0.01, 0.1, 1]
best_acc = 0
best_config = None

for kernel in ["linear", "rbf"]:
    for C in C_vals:
        if kernel == "rbf":
            for gamma in gamma_vals:
                clf = SVC(kernel=kernel, C=C, gamma=gamma)
                clf.fit(X_train, y_train)
                acc = accuracy_score(y_test, clf.predict(X_test))
                params.append((kernel, C, gamma, acc))
                if acc > best_acc:
                    best_acc = acc
                    best_config = (kernel, C, gamma)
        else:
            clf = SVC(kernel=kernel, C=C)
            clf.fit(X_train, y_train)
            acc = accuracy_score(y_test, clf.predict(X_test))
            params.append((kernel, C, None, acc))
            if acc > best_acc:
                best_acc = acc
                best_config = (kernel, C, None)

# tampilkan beberapa hasil    "tampilkan": Unknown word.
import pandas as pd
results = pd.DataFrame(params, columns=["kernel","C","gamma","accuracy"])
print(results.sort_values(by="accuracy", ascending=False).head(10))
print("\nModel terbaik:", best_config, "-> akurasi", round(best_acc,3))    "terbaik": Unknown word.

# laporan untuk model terbaik    "laporan": Unknown word.
kernel, C, gamma = best_config
if kernel == "rbf":
    best_model = SVC(kernel=kernel, C=C, gamma=gamma)
else:
    best_model = SVC(kernel=kernel, C=C)
best_model.fit(X_train, y_train)
print("\nLaporan klasifikasi model terbaik:")    "Laporan": Unknown word.
print(classification_report(y_test, best_model.predict(X_test), target_names=sumber.target_names))    "sumber": Unknown word.
```

```
    kernel      C  gamma  accuracy
0   linear    0.1    NaN  0.982456
12     rbf   10.0  0.001  0.982456
16     rbf  100.0  0.001  0.982456
13     rbf   10.0  0.010  0.982456
18     rbf  100.0  0.100  0.964912
10     rbf    1.0  0.100  0.964912
2   linear   10.0    NaN  0.964912
5      rbf    0.1  0.010  0.964912
14     rbf   10.0  0.100  0.964912
8      rbf    1.0  0.001  0.964912

Model terbaik: ('linear', 0.1, None) -> akurasi 0.982

Laporan klasifikasi model terbaik:
              precision    recall  f1-score   support

   malignant       1.00      0.95      0.98        43
      benign       0.97      1.00      0.99        71

    accuracy                           0.98       114
   macro avg       0.99      0.98      0.98       114
weighted avg       0.98      0.98      0.98       114
```

- params = []

  C_vals = [0.1, 1, 10, 100]

  gamma_vals = [0.001, 0.01, 0.1, 1]

  best_acc = 0

  best_config = None

Digunakan untuk:

Meyiapkan daftar parameter yang akan diuji untuk mencari kombinasi terbaik.

- for kernel in ["linear", "rbf"]:

```
for C in C_vals:
    if kernel == "rbf":
        for gamma in gamma_vals:
            clf = SVC(kernel=kernel, C=C, gamma=gamma)
            clf.fit(X_train, y_train)
            acc = accuracy_score(y_test, clf.predict(X_test))
            params.append((kernel, C, gamma, acc))
            if acc > best_acc:
                best_acc = acc
                best_config = (kernel, C, gamma)
    else:
        clf = SVC(kernel=kernel, C=C)
        clf.fit(X_train, y_train)
        acc = accuracy_score(y_test, clf.predict(X_test))
        params.append((kernel, C, None, acc))
        if acc > best_acc:
            best_acc = acc
           best_config = (kernel, C, None)
```

Digunakan untuk:

Melakukan pencarian kombinasi parameter C dan gamma untuk kernel linear dan RBF, lalu menyimpan hasil akurasi terbaik.

- import pandas as pd

  Digunakan untuk:

  Memanggil library pandas untuk manipulasi data tabel, seperti membuat dan mengurutkan dataframe hasl tuning

- results = pd.DataFrame(params,

  columns=["kernel","C","gamma","accuracy"])

  print(results.sort_values(by="accuracy", ascending=False).head(10))

```
print("\nModel terbaik:", best_config, "-> akurasi", round(best_acc,3))
```

Digunakan untuk:

Digunakan untuk:

Menampilkan 10 kombinasi parameter terbaik berdasarkan akurasi dan mencetak konfigurasi model terbaik.

- ```
  kernel, C, gamma = best_config
  if kernel == "rbf":
    best_model = SVC(kernel=kernel, C=C, gamma=gamma)
  else:
    best_model = SVC(kernel=kernel, C=C)
  best_model.fit(X_train, y_train)
  print("\nLaporan klasifikasi model terbaik:")
  print(classification_report(y_test, best_model.predict(X_test), target_names=sumber.target_names))
  ```

  Digunakan untuk:

  Melatih ulang model dengan parameter terbaik dan menampilkan laporan klasifikasi akhir.

  Di bagian ini saya menyiapkan rentang nilai untuk parameter `C` dan `gamma` (khusus RBF). Kemudian saya menjalankan dua lapis perulangan: pertama memilih kernel linear atau RBF, lalu mencoba masing-masing nilai C (dan juga gamma untuk RBF). Setiap kombinasi dilatih dan diuji, akurasinya dicatat ke daftar `params`.

  Setelah semua kombinasi diperiksa, saya menyusun hasil ke dalam DataFrame pandas agar mudah diurutkan. Saya menampilkan sepuluh kombinasi teratas berdasarkan akurasi dan menyimpan konfigurasi terbaik di `best_config`. Terakhir saya membangun ulang model dengan parameter terbaik dan mencetak laporan klasifikasi sebagai ringkasan.
  ```

3. Kesimpulan
   a. Kernel linear dan RBF keduanya dapat memberikan akurasi tinggi pada dataset kanker payudara, tetapi RBF umumnya lebih fleksibel ketika data tidak dapat dipisahkan secara linier.
   b. Parameter `C` mempengaruhi seberapa ketat model mematuhi data latih: nilai besar cenderung overfit, nilai kecil lebih umum. `gamma` pada RBF mengontrol kompleksitas batas; nilai terlalu tinggi menyebabkan model menangkap noise.
   c. Tuning sederhana meningkatkan akurasi sedikit, tetapi kedua kernel sudah sangat baik di dataset ini; pemilihan kernel sering bergantung pada karakteristik data.