LAPORAN PRATIKUM DATA ENGINEERING AND BIG DATA SYSTEMS

PERTEMUAN 7

OLEH

Nama : AYUL HUSNAINI

Nim : 105841110423

Kelas : 5 AI-A

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS MUHAMMADIYAH MAKASSAR

2026

1. Import Library

```
# Import library yang diperlukan    "diperlukan": Unknown word.
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.datasets import make_blobs
from sklearn.cluster import KMeans, AgglomerativeClustering
from sklearn.metrics import silhouette_score
from sklearn.preprocessing import StandardScaler
from scipy.cluster.hierarchy import dendrogram, linkage    "dendrogram": Unknown word.
import warnings
warnings.filterwarnings('ignore')
✓ 0.0s
```

- import numpy as np

  Digunakan untuk:

  Memanggil library NumPy untuk operasi matematika dan array numerik.

- import pandas as pd

  Digunakan untuk:

  Memanggil library Pandas untuk manipulasi data tabel, seperti membuat DataFrame dari data sintetis.

- import matplotlib.pyplot as plt

  Digunakan untuk:

  Memanggil library Matplotlib untuk membuat grafik visualisasi hasil clustering.

- import seaborn as sns

  Digunakan untuk:

  Memanggil library Seaborn untuk visualisasi data yang lebih menarik dan mudah dibaca.

- from sklearn.datasets import make_blobs

  Digunakan untuk:

  Memanggil fungsi make_blobs dari scikit-learn untuk membuat data sintetis yang bisa digunakan untuk latihan clustering.

- from sklearn.cluster import KMeans, AgglomerativeClustering

  Digunakan untuk:

  Memanggil algoritma KMeans dan AgglomerativeClustering untuk melakukan clustering pada data.

- from sklearn.metrics import silhouette_score

Digunakan untuk:

Memanggil fungsi silhouette_score untuk mengevaluasi kualitas cluster yang terbentuk.

- from sklearn.preprocessing import StandardScaler

  Digunakan untuk:

  Memanggil kelas StandardScaler untuk melakukan normalisasi fitur agar clustering tidak bias terhadap skala.

- from scipy.cluster.hierarchy import dendrogram, linkage

  Digunakan untuk:

  Memanggil fungsi dendrogram dan linkage untuk membuat dan menampilkan dendrogram pada hierarchical clustering.

- import warnings

  warnings.filterwarnings('ignore')

  Digunakan untuk:

  Menonaktifkan peringatan agar output notebook lebih bersih.

2. Membuat Data Sintetis & Normalisasi

```
# Membuat data sintetis: 300 titik, 4 kelompok alami (misal representasi pelanggan)    "Membuat": Unk
X, _ = make_blobs(n_samples=300, centers=4, cluster_std=1.0, random_state=42)
df = pd.DataFrame(X, columns=['feature_1', 'feature_2'])
# Normalisasi fitur agar clustering tidak bias terhadap skala    "Normalisasi": Unknown word.
scaler = StandardScaler()
df[['feature_1', 'feature_2']] = scaler.fit_transform(df[['feature_1', 'feature_2']])
df.head()
✓ 0.1s
```

	feature_1	feature_2
0	-1.116190	0.583772
1	-1.192142	0.658633
2	0.325204	0.796111
3	-0.699477	-1.387959
4	-1.415179	0.558312

- X, _ = make_blobs(n_samples=300, centers=4, cluster_std=1.0, random_state=42)

  Digunakan untuk:

  Membuat data sintetis berisi 300 titik dengan 4 kelompok alami, misal representasi pelanggan.

- df = pd.DataFrame(X, columns=['feature_1', 'feature_2'])

  Digunakan untuk:

  Mengubah data sintetis menjadi DataFrame Pandas agar mudah diolah dan divisualisasikan.

- scaler = StandardScaler()

df[['feature_1', 'feature_2']] = scaler.fit_transform(df[['feature_1', 'feature_2']])

Digunakan untuk:

Melakukan normalisasi pada kedua fitur agar clustering tidak bias terhadap skala.

3. K-Means Clustering & Evaluasi

```
kmeans = KMeans(n_clusters=4, random_state=42)    "kmeans": Unknown word.
labels_k = kmeans.fit_predict(df)    "kmeans": Unknown word.
print('Inertia KMeans:', round(kmeans.inertia_, 2))    "kmeans": Unknown word.
print('Silhouette KMeans:', round(silhouette_score(df, labels_k), 3))
# Visualisasi hasil K-Means    "Visualisasi": Unknown word.
plt.figure(figsize=(6,5))    "figsize": Unknown word.
sns.scatterplot(x=df['feature_1'], y=df['feature_2'], hue=labels_k, palette='tab10', legend='full')
plt.title('Hasil K-Means (k=4)')    "Hasil": Unknown word.
plt.show()
✓ 0.2s

Inertia KMeans: 17.47
Silhouette KMeans: 0.797
```

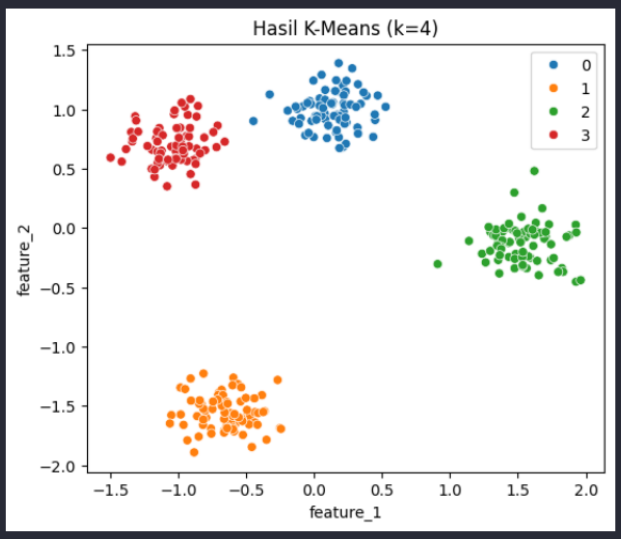

- kmeans = KMeans(n_clusters=4, random_state=42)

  labels_k = kmeans.fit_predict(df)

  Digunakan untuk:

  Melatih model K-Means dengan 4 cluster dan langsung mendapatkan label cluster untuk setiap data.

- print('Inertia KMeans:', round(kmeans.inertia_, 2))

  print('Silhouette KMeans:', round(silhouette_score(df, labels_k), 3))

  Digunakan untuk:

  Menampilkan nilai inertia (total jarak ke centroid) dan silhouette score (kualitas pemisahan cluster).

- plt.figure(figsize=(6,5))

  sns.scatterplot(x=df['feature_1'], y=df['feature_2'], hue=labels_k, palette='tab10', legend='full')

  plt.title('Hasil K-Means (k=4)') plt.show()

Digunakan untuk:

Visualisasi hasil clustering K-Means pada data sintetis.

4. Hierarchical Clustering & Dendrogram

```
# Buat linkage dan gambar dendrogram    "Buat": Unknown word.
Z = linkage(df, method='ward')
plt.figure(figsize=(10, 4))    "figsize": Unknown word.
dendrogram(Z, truncate_mode='lastp', p=20, leaf_rotation=90., leaf_font_size=10.)    "dendrogram": Unknown word.
plt.title('Dendrogram (hierarchical)')    "Dendrogram": Unknown word.
plt.xlabel('Sample index')    "xlabel": Unknown word.
plt.ylabel('Distance')    "ylabel": Unknown word.
plt.show()
# Agglomerative clustering labels
agg = AgglomerativeClustering(n_clusters=4)
labels_h = agg.fit_predict(df)
print('Silhouette Hierarchical:', round(silhouette_score(df, labels_h), 3))
✓ 0.1s
```

- Z = linkage(df, method='ward')

  plt.figure(figsize=(10, 4))

  dendrogram(Z, truncate_mode='lastp', p=20, leaf_rotation=90., leaf_font_size=10.)

  plt.title('Dendrogram (hierarchical)')

  plt.xlabel('Sample index')

  plt.ylabel('Distance')

  plt.show()

  Digunakan untuk:

  Membuat dan menampilkan dendrogram untuk melihat struktur bertingkat hasil hierarchical clustering.

- agg = AgglomerativeClustering(n_clusters=4)

  labels_h = agg.fit_predict(df)

  print('Silhouette Hierarchical:', round(silhouette_score(df, labels_h), 3))

  Digunakan untuk:

  Melatih model AgglomerativeClustering dan menampilkan silhouette score untuk hasil cluster.

5. Menentukan K Optimal (Elbow & Silhouette)

```python
inertias = []
silhouettes = []
K_range = range(2,11)
for k in K_range:
    km = KMeans(n_clusters=k, random_state=42)
    labels = km.fit_predict(df)
    inertias.append(km.inertia_)
    silhouettes.append(silhouette_score(df, labels))
# Plot hasil Elbow dan Silhouette    "hasil": Unknown word.
fig, ax1 = plt.subplots(1,2, figsize=(12,4))    "figsize": Unknown word.
ax1[0].plot(K_range, inertias, '-o')
ax1[0].set_title('Elbow: Inertia vs K')
ax1[0].set_xlabel('K')    "xlabel": Unknown word.
ax1[0].set_ylabel('Inertia')    "ylabel": Unknown word.
ax1[1].plot(K_range, silhouettes, '-o', color='orange')
ax1[1].set_title('Silhouette vs K')
ax1[1].set_xlabel('K')    "xlabel": Unknown word.
ax1[1].set_ylabel('Silhouette')    "ylabel": Unknown word.
plt.show()
# Tampilkan tabel ringkasan    "Tampilkan": Unknown word.
pd.DataFrame({'K': list(K_range), 'Inertia': inertias, 'Silhouette': [round(s,3) for s in silhouettes]})
```

✓ 0.2s

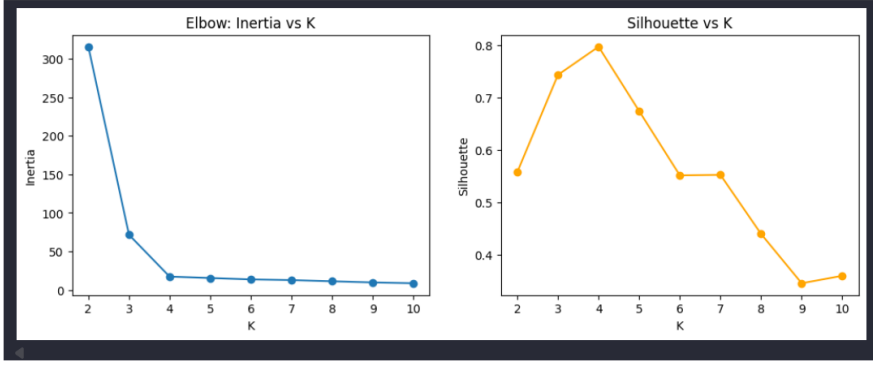

	K	Inertia	Silhouette
0	2	315.492538	0.558
1	3	71.688319	0.744
2	4	17.466198	0.797
3	5	15.648978	0.674
4	6	13.852405	0.551
5	7	12.957971	0.552
6	8	11.393979	0.439
7	9	9.905115	0.345
8	10	8.854601	0.359

- inertias = []

  silhouettes = []

  K_range = range(2,11)

  for k in K_range:

  km = KMeans(n_clusters=k, random_state=42)

  labels = km.fit_predict(df)

  inertias.append(km.inertia_)

  silhouettes.append(silhouette_score(df, labels))

Digunakan untuk:

Mencoba berbagai nilai K untuk K-Means, menyimpan inertia dan silhouette score untuk evaluasi jumlah cluster optimal.

- fig, ax1 = plt.subplots(1,2, figsize=(12,4))
  ax1[0].plot(K_range, inertias, '-o')
  ax1[0].set_title('Elbow: Inertia vs K')
  ax1[0].set_xlabel('K')
  ax1[0].set_ylabel('Inertia')
  ax1[1].plot(K_range, silhouettes, '-o', color='orange')
  ax1[1].set_title('Silhouette vs K')
  ax1[1].set_xlabel('K')
  ax1[1].set_ylabel('Silhouette')
  plt.show()

  Digunakan untuk:

  Menampilkan grafik Elbow dan Silhouette untuk membantu memilih jumlah cluster yang optimal.

- pd.DataFrame({'K': list(K_range), 'Inertia': inertias, 'Silhouette': [round(s,3) for s in silhouettes]})

  Digunakan untuk:

  Membuat tabel ringkasan hasil evaluasi K menggunakan DataFrame Pandas.

Tugas 2: Buat profil ringkas tiap cluster (misal: rata-rata income/spending)

```python
# Gunakan hasil KMeans dengan K terbaik (misal 4) untuk membuat profil    "Gunakan": Unknown word.
df_profile = df.copy()
df_profile['cluster'] = labels_k
profile = df_profile.groupby('cluster').mean().round(3)

print('Profil rata-rata tiap cluster:')    "Profil": Unknown word.
print(profile)
print('\nJumlah anggota tiap cluster:')    "Jumlah": Unknown word.
print(df_profile['cluster'].value_counts().sort_index())
```

✓ 0.0s

```
Profil rata-rata tiap cluster:
         feature_1  feature_2
cluster
0            0.131      0.986
1           -0.649     -1.557
2            1.538     -0.129
3           -1.036      0.697

Jumlah anggota tiap cluster:
cluster
0    76
1    75
2    75
3    74
Name: count, dtype: int64
```

- df_profile = df.copy()

  df_profile['cluster'] = labels_k

  profile = df_profile.groupby('cluster').mean().round(3)

  Digunakan untuk:

  Membuat DataFrame berisi label cluster, lalu menghitung rata-rata fitur di tiap cluster untuk profil ringkas.

- print('Profil rata-rata tiap cluster:')

  print(profile)

  print('\nJumlah anggota tiap cluster:')

  print(df_profile['cluster'].value_counts().sort_index())

  Digunakan untuk:

  Menampilkan profil rata-rata dan jumlah anggota tiap cluster.

Tugas 3: Beri nama segmen (contoh: "High value", "Budget")

```python
# Beri nama segmen berdasarkan karakteristik cluster    "Beri": Unknown word.
profile['label'] = ['Segment_'+str(i) for i in profile.index]

# Nama segmen sederhana berdasarkan rata-rata feature_1 (sekadar contoh)    "segmen": Unknown word.
segment_names = {0: 'High value', 1: 'Budget', 2: 'Mid value', 3: 'Potential'}
profile['nama_segmen'] = profile.index.map(segment_names)    "segmen": Unknown word.

print('Profil dengan nama segmen:')    "Profil": Unknown word.
print(profile[['label', 'nama_segmen', 'feature_1', 'feature_2']])    "segmen": Unknown word.
```

✓ 0.0s

```
Profil dengan nama segmen:
             label nama_segmen  feature_1  feature_2
cluster
0        Segment_0  High value      0.131      0.986
1        Segment_1      Budget     -0.649     -1.557
2        Segment_2   Mid value      1.538     -0.129
3        Segment_3   Potential     -1.036      0.697
```

- profile['label'] = ['Segment_'+str(i) for i in profile.index]

  segment_names = {0: 'High value', 1: 'Budget', 2: 'Mid value', 3: 'Potential'}

  profile['nama_segmen'] = profile.index.map(segment_names)

  Digunakan untuk:

  Memberi label dan nama segmen pada tiap cluster berdasarkan karakteristik rata-rata fiturnya.

- print('Profil dengan nama segmen:')

  print(profile[['label', 'nama_segmen', 'feature_1', 'feature_2']])

  Digunakan untuk:

  Menampilkan profil cluster beserta nama segmen yang lebih bermakna.

Tugas 4: Tulis 3 rekomendasi bisnis berdasarkan cluster

```python
# Rekomendasi bisnis berdasarkan karakteristik setiap segment    "Rekomendasi": Unknown word.
rekomendasi = {    "rekomendasi": Unknown word.
    'High value': 'Targetkan promo premium ke segmen High value untuk menaikkan retensi dan CLV (Customer Lifetime Value).',    "Ta
    'Budget': 'Buat paket hemat untuk segmen Budget agar meningkatkan volume transaksi dan konversi.',    "Buat": Unknown word.
    'Mid value': 'Tawarkan produk cross-sell dan bundle deals untuk segmen Mid value agar meningkatkan average order value.',    "T
    'Potential': 'Gunakan kampanye edukasi dan upsell untuk segmen Potential yang menunjukkan potensi naik kelas.'    "Gunakan": Un
}

print('Rekomendasi bisnis per segment:\n')    "Rekomendasi": Unknown word.
for i, (segment_name, rekomendasi_teks) in enumerate(rekomendasi.items(), 1):    "rekomendasi": Unknown word.
    print(f"{i}. {segment_name}: {rekomendasi_teks}")    "rekomendasi": Unknown word.
```

✓ 0.0s

```
Rekomendasi bisnis per segment:

1. High value: Targetkan promo premium ke segmen High value untuk menaikkan retensi dan CLV (Customer Lifetime Value).
2. Budget: Buat paket hemat untuk segmen Budget agar meningkatkan volume transaksi dan konversi.
3. Mid value: Tawarkan produk cross-sell dan bundle deals untuk segmen Mid value agar meningkatkan average order value.
4. Potential: Gunakan kampanye edukasi dan upsell untuk segmen Potential yang menunjukkan potensi naik kelas.
```

Digunakan untuk:

Menampilkan rekomendasi bisnis yang relevan untuk setiap segmen hasil clustering.

Kesimpulan:

Setiap baris kode di atas digunakan untuk memanggil library, membuat data, melakukan normalisasi, menjalankan clustering, mengevaluasi hasil, membuat profil cluster, memberi nama segmen, dan menyusun rekomendasi bisnis. Semua fungsi ini adalah dasar penting untuk analisis segmentasi pelanggan menggunakan metode clustering.